

實務專題研究報告

題目

整合大型語言模型與即時開放資料於動態交通號誌優化之
研究：以 SUMO 模擬為驗證場域流程

專題基本資料

專題編號：114-2-CSIE-S016

執行期限：114 年第 1 學期至 114 年第 2 學期

指導教授：陳香君

專題參與人員：112590060 伍紹文、112590045 邱兆偉、112590049 吳宜峰、112590048
劉柏漢

中文摘要

本研究以國立臺北科技大學周邊路網為實驗區域，建構整合即時開放資料、交通模擬、深度學習預測與大型語言模型解釋介面的智慧號誌決策支援系統 TrafficVision。系統透過台北市 VD 開放資料取得即時車流，並以 SUMO 建立微觀模擬環境作為可驗證場域。其核心為一條「預測驅動」的決策流程：先以雙通道 GRU 模型預測未來五分鐘各路段車流量與平均車速，再依預測之壅塞樣態，於多種號誌控制策略間並行模擬與加權選優。

在預測層，GRU pair model 於模擬 holdout 之車速通道平均絕對誤差較 persistence 基準改善 87.7%、車流通道改善 58.8%。在優化層，405 次有效自動排程模擬顯示，系統最佳策略相較無控制基準平均降低等待時間 8.6%、行程延誤 7.3%（配對檢定 $p < .001$ ）；改善幅度並隨壅塞加劇而上升，於高壅塞情境（無控制等待時間前 25%）達 10.4%、前 10% 達 12.5%。進一步分析顯示，預測驅動的動態選擇優於任何單一固定策略，於 74.8% 的情境中勝過最佳固定策略；權重敏感度分析亦證實策略選擇對評分權重穩健。

系統並以 React 與 Leaflet 儀表板呈現當前、預測與優化三種視角，另以本地部署之微調 Gemma 模型作為輔助解釋介面，將號誌調整依據以自然語言說明。實驗結果顯示 TrafficVision 具備即時資料整合、模擬驗證與決策輔助之可行性。未來將導入圖神經網路建模路段間空間關聯，並評估與實際號誌控制器串接之可能。

關鍵詞：交通號誌控制、智慧交通系統、SUMO、GRU、即時開放資料、短時車流預測、大型語言模型

ABSTRACT

This study develops TrafficVision, an intelligent traffic-signal decision-support system for the road network around National Taipei University of Technology, integrating real-time open data, microscopic simulation, deep-learning prediction, and a large language model explanation interface. The system ingests vehicle-detector (VD) data from the Taipei City open-data platform and reconstructs demand in a SUMO microscopic simulation that serves as a verifiable testbed. Its core is a prediction-driven decision loop: a dual-channel GRU model forecasts per-edge traffic volume and mean speed for the next five minutes, and the predicted congestion profile then guides a parallel, weighted comparison of several signal-control strategies.

For prediction, the GRU pair model reduces speed-channel mean absolute error by 87.7% and flow-channel error by 58.8% relative to a persistence baseline on a simulation holdout. For optimization, across 405 valid auto-scheduled runs the best strategy lowers average waiting time by 8.6% and travel delay by 7.3% against an uncontrolled baseline (paired test $p < .001$), with the gain growing under congestion: 10.4% for the most-congested quartile and 12.5% for the top decile. The prediction-driven dynamic selection outperforms any single fixed strategy, beating the best fixed strategy in 74.8% of cases, and a weight-sensitivity analysis confirms the selection is robust to the scoring weights.

A React/Leaflet dashboard presents current, predicted, and optimized views, while a locally deployed fine-tuned Gemma model acts as an auxiliary interface that explains the signal decisions in natural language. The results demonstrate the feasibility of combining real-time data, simulation-based verification, and decision support for urban signal optimization. Future work will incorporate graph neural networks to model inter-edge spatial dependency and assess integration with physical signal controllers.

Keywords: Traffic Signal Control, Intelligent Transportation System, SUMO, GRU, Real-Time Open Data, Short-Term Traffic Prediction, Large Language Model

誌謝

本專題得以完成，首先感謝指導教授陳香君老師於研究方向、系統架構與報告撰寫上的指導，使本團隊能逐步釐清智慧交通號誌控制之研究問題，並將即時資料、交通模擬與人工智慧模型整合為完整系統。感謝團隊成員於資料處理、SUMO 模擬、模型訓練、前端視覺化與 AI 問答介面開發過程中的分工與協作。亦感謝臺北市交通資料開放平台提供即時交通資料，使本研究得以在貼近真實場域的基礎上進行模擬與驗證。

目錄

中文摘要

英文摘要

誌謝

目錄

表目錄

圖目錄

第一章 緒論

第二章 文獻回顧與技術基礎

第三章 研究方法與系統架構

第四章 系統實作

第五章 實驗設計與結果分析

第六章 結論與未來展望

參考文獻

附錄

符號彙編

表目錄

表 5.1 號誌控制策略比較表

表 5.2 各策略平均等待時間與行程延誤比較表

表 5.3 系統功能完成度整理表

圖目錄

圖 3.1 系統整體架構流程圖

圖 4.1 SUMO 模擬路網畫面

圖 4.2 TrafficVision 儀表板畫面

圖 5.1 不同號誌策略平均等待時間比較圖

圖 5.2 當前、預測與優化三種視角之車流熱力圖

第一章 緒論

1.1 研究背景

近年來，台灣都市化快速發展，道路機動車輛數與尖峰交通量持續攀升，主要幹道在通勤時段經常出現壅塞情形，並進一步影響周邊巷道與交會路口之通行效率。都市交

通壅塞不僅造成民眾通勤時間增加，也會導致能源消耗、空氣污染與交通安全風險提升，因此如何有效改善路口號誌控制，已成為智慧城市與智慧交通系統發展中的重要議題。

目前多數都市路口仍以固定時制號誌為主要控制方式。固定時制號誌雖具有設計簡單、維護容易及穩定運作等優點，但其缺點在於難以即時反映短時間內的車流變化。當車流量較低時，固定秒數可能造成不必要等待；當車流量突然升高時，既定綠燈時間又可能不足以消化車隊，導致排隊長度增加與路口回堵。尤其在都會區道路密集且車流變動快速的情境下，傳統固定時制控制模式已逐漸難以滿足即時交通管理需求。

隨著政府開放資料、交通感測設備、微觀交通模擬與人工智慧技術日益成熟，交通管理已具備從固定控制轉向資料驅動決策的可能。本研究以北科大周邊道路作為實驗場域，嘗試整合台北市 VD 即時交通資料、SUMO 微觀交通模擬、GRU 短時車流預測與大型語言模型互動介面，建構一套可支援交通號誌優化之智慧決策系統。

1.2 研究動機

台北市已提供即時交通開放資料，包含車速、車流量與道路狀態等資訊，然而這些資料若僅作為靜態查詢或單純展示，仍難以直接轉換為號誌控制決策。交通管理人員在調整號誌秒數時，通常需要依靠現地觀察、歷史經驗與反覆測試，過程耗時且不易即時反應突發車流變化。

此外，現有許多智慧交通研究著重於演算法本身，例如深度學習或強化學習模型，但較少完整整合資料蒐集、模擬驗證、策略比較、視覺化呈現與人機互動說明。若缺乏可驗證的模擬場域與清楚的結果呈現方式，即使模型能產生號誌調整建議，也不容易被交通管理單位理解與採用。

因此，本研究希望建立一套完整流程：從即時資料取得開始，經由資料正規化與 SUMO 模擬，進一步利用 GRU 預測短時間車流變化，再透過多策略並行模擬比較不同號誌控制方式之效果，最後以儀表板與 AI 問答介面呈現結果，使系統不僅能提出建議，也能解釋建議形成的依據。

1.3 研究目的

本研究之主要目的為開發一套整合即時交通資料、SUMO 模擬、GRU 車流預測與大型語言模型互動介面之智慧交通號誌決策支援系統。具體目標如下：

- 一、建置北科大周邊路網之 SUMO 微觀交通模擬環境，作為號誌策略驗證場域。
- 二、串接台北市 VD 開放資料，建立即時車流資料擷取、清理、範圍過濾與座標映射流程。
- 三、以 GRU 模型進行未來 5 分鐘短時車流預測，提升系統對即時交通變化的預判能力。
- 四、設計多種號誌控制策略，並透過 SUMO 並行模擬比較平均等待時間、行程延誤等指標。
- 五、建構前端視覺化儀表板，呈現當前、預測與優化三種交通視角。
- 六、導入經微調之 Gemma 4 模型，提供自然語言問答與決策說明功能，使使用者能理解系統分析結果。

1.4 研究範圍

本研究以國立臺北科技大學周邊道路作為主要實驗範圍，涵蓋市民大道、八德路、忠孝東路及新生南路等主要路段。研究路網包含約 230 條 SUMO edge（其中約 120 條為命名道路 edge，其餘為內部 junction edge）與 17 個受號誌控制路口。系統資料來源主要為台北市 VD 開放資料，並以 SUMO 模擬生成車流與號誌控制結果。

本研究聚焦於模擬環境中的號誌策略評估與決策支援，尚未直接控制真實交通號誌設備。因此，本研究成果可視為實際交通控制系統導入前之模擬驗證平台，協助後續評估不同策略在實務場域中的可行性。

1.5 研究貢獻

本研究之貢獻可歸納為四點。第一，建立一套以即時 VD 開放資料驅動之 SUMO 微

觀交通模擬流程，使真實交通資料能轉換為可驗證之模擬場景。第二，導入 GRU 進行短時車流預測，使號誌策略不僅反映當前路況，也能考量短時間後的車流趨勢。第三，設計多策略並行模擬與加權評分機制，使系統能以量化方式比較不同號誌控制策略。第四，結合前端儀表板與大型語言模型問答介面，提高系統結果的可視性與可理解性。

第二章 文獻回顧與技術基礎

2.1 智慧城市交通號誌控制

智慧交通系統是智慧城市發展中的重要應用之一，其核心目標在於透過感測器、通訊網路、資料分析與自動化控制技術，提高道路使用效率並降低壅塞。傳統交通號誌多採固定時制設計，依據歷史交通量與尖離峰時段預先設定週期與綠燈秒數。此方法適合交通流量相對穩定的情境，但在車流高度變動、突發事件或區域活動影響下，固定時制難以及時反映道路狀況。

為改善固定時制的不足，感應式控制、自適應控制與 AI 輔助號誌控制逐漸受到重視。感應式控制可依車輛偵測結果調整綠燈秒數，自適應控制則進一步根據整體路網狀態進行動態調整。近年研究亦導入深度學習與強化學習模型，使系統能根據交通狀態自動學習較佳控制策略。然而，若缺乏可驗證之模擬環境與清楚的結果解釋，AI 控制策略在實務導入時仍會面臨可信度與可操作性問題。

2.2 都市交通模擬與 SUMO

SUMO (Simulation of Urban Mobility) 是一套開源微觀交通模擬工具，可模擬車輛、行人、道路、路口號誌與不同交通情境下的流動行為。相較於直接在真實道路測試號誌控制策略，SUMO 能在不影響實際交通安全與道路運作的情況下，進行多種策略比較與效能分析。

SUMO 支援由 OpenStreetMap 匯入道路資料，建立接近真實環境的路網結構，並可透過 trip、route 等檔案設定車流需求與行駛路徑。此外，SUMO 亦支援 TraCI 介面，

使研究者能於模擬過程中即時取得車輛位置、速度、路段密度、號誌相位與倒數時間等資訊，並可動態修改號誌控制參數。因此，SUMO 適合用於本研究之號誌策略模擬與驗證。

2.3 即時開放資料與資料處理

政府開放資料提供即時道路速率、車流量與道路狀態等資訊，是智慧交通系統的重要資料來源。然而，開放資料通常涵蓋範圍廣、格式不一定能直接對應特定模擬場域，因此需要經過資料清理、範圍過濾、座標轉換與道路對應等前處理流程。

本研究使用台北市交通局 VD 開放資料作為即時車流資料來源。由於 API 回傳座標採用 WGS84 經緯度格式，而 SUMO 模擬路網使用自身座標系，因此需進行座標映射，使實際道路位置能對應至 SUMO 地圖中的相對位置。經過正規化與篩選後，系統可將真實車流資訊轉換為模擬需求，並支援後續模型預測與號誌策略評估。

2.4 短時車流預測與 GRU 模型

短時車流預測是智慧交通系統中的關鍵任務，其目的在於根據近期交通狀態推估未來數分鐘內的車流變化。交通流量具有時間序列特性，會受到通勤尖峰、道路容量、號誌週期與周邊車流互動影響，因此適合使用循環神經網路或其變形模型進行建模。

GRU（Gated Recurrent Unit）是一種循環神經網路架構，能透過門控機制保留重要時間資訊並降低長序列訓練困難。相較於傳統 RNN，GRU 較能捕捉時間序列中的變化趨勢，也具有參數量相對較少、訓練效率較佳的優點。本研究採用 GRU 預測未來 5 分鐘車流，使號誌策略評估能同時考量當前狀態與短期趨勢。

2.5 大型語言模型與決策說明

大型語言模型在本研究中並不直接負責交通號誌數值優化，而是作為系統輸出結果的自然語言互動介面。其主要功能為根據後端產生之結構化資料，將交通狀態、壅塞原因、號誌調整邏輯與預期改善效果轉換為使用者容易理解的文字說明。

本研究使用 Ollama 作為本地推論服務，並導入經微調之 Gemma 4 模型。透過本地化部署，可降低外部網路依賴，並讓 AI 助理基於系統資料回答問題，避免模型自行臆

測交通決策。此設計能提升系統可解釋性，使交通管理人員更容易理解模型結果與號誌策略建議。

第三章 研究方法與系統架構

3.1 系統設計理念

本研究採用「資料監測—模擬驗證—預測分析—策略評估—互動呈現」的設計理念。系統不僅顯示即時路況，也會將即時資料轉換為 SUMO 模擬需求，進一步透過 GRU 預測未來車流，並比較多種號誌控制策略的效能。最後，系統將結果呈現於前端儀表板，並由 AI 助理提供自然語言說明。

整體而言，TrafficVision 並非單一模型，而是一套完整的交通決策支援流程。其價值在於將即時資料、微觀模擬、深度學習與人機互動整合於同一平台，使交通管理人員能從「目前發生什麼」、「接下來可能發生什麼」以及「如何調整較有效」三個層面理

解交通狀態。

3.2 系統整體流程

本系統可分為兩條資料流。第一條為即時 VD 資料流，負責定期抓取台北市交通局車流資料，並將當前車速、流量與壅塞等級呈現於前端儀表板。第二條為完整 ML 管線，依序執行資料抓取、資料正規化、路徑生成、SUMO 微觀模擬、GRU 預測、號誌策略評估與結果輸出。

系統排程器每 5 分鐘自動觸發一次資料更新與分析流程，使儀表板能維持與實際路況接近的狀態。當系統取得新資料後，會將資料轉換為模擬輸入，執行多策略並行模擬，並將各策略的平均等待時間與行程延誤轉換為加權分數，最後選出最佳策略作為建議結果。

3.3 資料取得與正規化方法

本研究透過台北市 VD 開放資料取得即時車流資料。由於原始資料涵蓋範圍大於本研究區域，系統需先根據研究區域邊界進行範圍過濾，保留與北科大周邊道路相關之路段資料。

在座標處理方面，由於 API 回傳之座標採 WGS84 經緯度格式，無法直接與 SUMO 模擬座標系對應，因此本研究使用線性轉換方法將經緯度映射至 SUMO 地圖座標。轉換完成後，系統會檢查路段端點是否落在研究範圍內；若部分端點位於範圍外，則透過距離比對尋找最近路口作為替代位置，以降低資料與模擬路網不一致造成的誤差。

3.4 路徑生成與模擬建置

取得完整起點與終點資料後，本研究使用 SUMO 提供的 duarouter 工具進行路線配置。duarouter 會根據道路結構、連通關係與邊權重，計算每筆旅次的行駛路徑，並輸出 SUMO 所需之 route 檔案。

由於單次 duarouter 通常會產生單一路徑，若所有車流皆使用同一條最佳路徑，可能降低模擬場景真實性。因此，本研究採用迭代式方式生成多組候選路徑，並加入隨機化

權重，使路徑配置具備一定差異性。此方法能使模擬車流分布更接近實際道路情境，避免過度集中於單一路段。

3.5 GRU 車流預測方法

本研究以 GRU pair model 預測未來 5 分鐘交通狀態。模型輸入包含近期 15 個 timestep（每步 20 秒，共 5 分鐘）之路段車流量、平均車速與時間特徵（sin/cos 編碼之日內時間、距上次抓取之 gap_minutes）。模型輸出為未來 15 個 timestep 之雙通道預測結果，包含每個路段之預測車流量（vehicle_count）與預測平均車速（avg_speed_kmh）。預測結果將作為後續號誌策略評估的依據，使系統不僅依據當前路況進行調整，也能考量即將發生的車流變化與速度趨勢。預測結果將作為後續號誌策略評估的依據，使系統不僅依據當前路況進行調整，也能考量即將發生的車流變化。

在高流量路段中，車流變化較容易造成延滯與回堵，因此本研究在模型設計與策略評估時特別重視高流量路段之預測準確性。透過 GRU 的時間序列學習能力，系統可在短期內預判車流壓力，並提供較即時的號誌控制建議。

3.6 號誌策略評估方法

本研究設計多種號誌控制策略進行並行模擬比較，包括無控制基準、固定時制、依壅塞程度調整之 adaptive 策略，以及其他根據預測車流變化調整綠燈秒數之策略。每一種策略皆在相同模擬環境中執行，以確保比較基準一致。

系統以平均等待時間與行程延誤作為主要評估指標，並透過加權分數整合不同指標。若某策略能降低等待時間與延誤，則其綜合分數較佳，系統將其視為建議方案。此設計使號誌策略選擇不依賴單一指標，而能同時考量車輛停等與整體行程效率。

3.7 儀表板與 AI 互動介面

前端儀表板以 React 建構，並使用 Leaflet 疊加 SUMO 路網與真實座標資訊，呈現道路熱力圖、車流狀態與策略評估結果。使用者可透過儀表板同時觀察當前路況、預測車流與優化結果。

AI 互動介面則以經微調之 Gemma 4 作為問答模型，並透過 Ollama 於本地部署。AI

助理的回答內容以系統後端產生之即時資料與模擬結果為基礎，主要負責解釋而非決策。例如，使用者可詢問特定路段壅塞原因、系統為何選擇某一號誌策略，以及預期改善效果為何。

第四章 系統實作

4.1 地圖生成與路網修正

本研究使用 SUMO 所提供之 OSMWebWizard 工具，根據 OpenStreetMap 資料匯入北科大周邊路網。初始匯入之地圖雖能快速建立道路結構，但仍可能存在節點、車道、轉向連接與號誌設定不一致等問題。因此，本研究於地圖生成後進行檢視與修正，使模擬路網更接近實際道路環境。

本研究採用之模擬範圍涵蓋市民大道、八德路、忠孝東路及新生南路等主要路段，並以北科大周邊之都市道路作為核心分析區域。此區域具備多路口、幹道與支線交會之交通特性，適合作為動態號誌控制策略之模擬場域。

4.2 API 即時車流資料擷取

系統透過台北市交通資料開放平台取得 VD 即時車流資料。資料擷取模組會定期呼叫 API，取得研究範圍周邊道路之車速、流量與道路狀態資訊。為確保系統能自動更新，資料抓取流程由排程器控制，每 5 分鐘執行一次。

擷取後的資料會先進行格式檢查與範圍篩選，剔除與研究區域無關之資料，再進一步轉換為 SUMO 可使用之模擬輸入。此流程使系統能持續反映接近真實狀態的交通情境。

4.3 資料正規化與座標映射

由於 VD 資料與 SUMO 使用不同座標系，系統需將經緯度轉換為 SUMO 地圖座標。轉換時先取得研究區域之最小經度、最大經度、最小緯度與最大緯度，再依據

SUMO 地圖於 X、Y 方向之長度進行比例縮放。

座標映射完成後，系統會檢查路段起點與終點是否位於模擬範圍內。若資料點與 SUMO 路網不完全吻合，則透過最近路口比對方式進行修正，以降低資料對應錯誤對後續模擬造成的影響。

4.4 車流路徑生成

在取得起點與終點資料後，系統產生 trip.xml 作為 SUMO 旅次輸入，並使用 duarouter 將旅次轉換為 route 檔案。為避免所有車輛集中於單一路徑，本研究採用多次迭代方式產生多組候選路徑，並於路徑生成過程中加入隨機化權重，使車輛路線更具多樣性。

此流程可提升模擬情境之真實性，使 SUMO 中的車流分布、道路負載與壅塞形成過程更接近實際交通狀況。

4.5 SUMO 模擬與 TraCI 資料擷取

完成路網與路徑設定後，系統在 SUMO 中建立完整交通模擬環境。模擬過程中，系統透過 TraCI 擷取即時交通與車流資訊，包括車輛位置、速度、加速度、路段密度、平均速度、壅塞程度、號誌相位與倒數時間等。

這些資料一方面供前端儀表板呈現即時模擬狀態，另一方面也作為 GRU 預測與號誌策略評估之基礎。TraCI 的即時控制能力亦使系統能於模擬中測試不同號誌策略，並觀察策略調整後之交通效果。

4.6 GRU 模型訓練與預測

GRU 模型以 SUMO 微觀模擬產生之多日車流時間序列資料作為訓練資料（共約 1.9 萬個訓練樣本與 5 千個 holdout 測試樣本），學習不同路段於短時間內的車流與速度變化模式。模型架構採用雙層 GRU（hidden_dim = 256, num_layers = 2）加上 attention 池化與全連接解碼層，input 維度為 $230 \times 2 + 3$ （230 個 edge 之車流與車速、加上 sin/cos/gap 時間特徵），output 維度為 230×2 （15 個 timestep $\times$ 2 個通道）。資料前處理採用 Log1pScaler（log1p / expm1 對數轉換）對車流量與車速同步正規化，避免高流

量路段主導損失函數。損失函數採用加權序列損失（weighted sequence loss），其中車流通道於高流量 cells（ $\text{target} > \log_{10}(10) \approx 2.4$ ）給予 $5\times$ 權重；車速通道則使用 has-vehicle mask 策略，僅對 $\text{target count} > 0$ 的 cells 計算 MSE，避免 dense matrix 中 $\text{fillna}(0)$ 之假零稀釋有效訊號。兩個通道之 loss 以 $\text{speed_loss_weight} = 0.5$ 加權後相加。實際訓練於 NVIDIA RTX 4060 Ti GPU 上執行，epochs 上限 60，early stoppingpatience = 8，於第 17 epoch 達最佳 validation loss 0.0930。Holdout 測試結果：車流通道 MAE 為 0.1273（相較 persistence baseline 0.3092 改善 58.8%），高流量路段 MAE 為 0.875（相較 persistence 2.27 改善 61.4%）；速度通道於真實有車路段之 MAE 為 3.78 km/h（相較 persistence 30.73 改善 87.7%）。

4.7 號誌控制策略與加權評分

本研究並行評估多種號誌控制策略。每種策略皆於相同模擬條件下執行，並記錄平均等待時間、行程延誤與其他交通指標。系統將各指標轉換為加權分數後，比較不同策略之優劣。

adaptive 策略會根據車流預測與壅塞程度，鎖定關鍵路口並動態延長綠燈秒數。此策略的目的在於於高流量方向提供較多通行時間，以降低車隊累積與路口回堵。

4.8 前端儀表板實作

前端使用 React 建構單頁式應用程式，並搭配 Leaflet 呈現地圖視覺化。儀表板主要提供三種視角：第一為當前車流狀態，呈現即時資料與模擬狀態；第二為預測車流狀態，呈現 GRU 模型預測結果；第三為優化後狀態，呈現系統選定策略後的改善情形。

此設計能協助使用者快速比較不同交通狀態，並理解號誌優化對路網造成的影響。

4.9 AI 問答介面實作

AI 問答介面以 Ollama 作為本地推論伺服器，並部署經微調之 Gemma 4 模型。使用者可透過自然語言詢問目前路況、特定路段壅塞原因、系統建議的號誌策略，以及預期改善效果。

為避免大型語言模型產生未依據資料的回答，本研究將 AI 助理定位為結果解釋介面，而非決策核心。AI 助理的回應需引用後端即時數據與模擬結果，使其回答內容具備可追溯性與可信度。本研究使用 Unsloth 框架對 Gemma 4 進行 LoRA 微調，訓練資料由系統實際運行之 handoff 數據（含號誌策略選擇、加權分數、預測結果）配對人工撰寫之解釋回答構成。微調後模型透過 export_to_gguf 轉換為 GGUF 格式，並於本地以 Ollama 服務部署。隨著系統持續運行，微調資料集將逐步擴增，使 AI 助理回答更貼近實際決策邏輯。

第五章 實驗設計與結果分析

5.1 實驗場域

本研究以北科大周邊道路作為實驗場域，路網涵蓋市民大道、八德路、忠孝東路及新生南路等主要道路。模擬環境中包含約 230 條 SUMO edge（其中約 120 條為命名道路 edge，其餘為內部 junction edge）與 17 個受號誌控制路口。此區域道路密集、路口數量多，且位於市中心交通流量較高之區域，因此適合作為智慧號誌控制策略之驗證場域。

5.2 實驗情境設計

本研究以 SUMO 建立微觀模擬情境，並使用即時 VD 資料與模擬生成資料建立不同交通流量條件。實驗情境可分為一般流量與高壅塞情境，其中高壅塞情境用以測試 adaptive 策略在車流壓力較大時是否能有效降低等待時間與延誤。

各策略皆在相同路網、相同車流需求與相同模擬條件下執行，以確保比較結果具有一致性。系統每次模擬後會記錄交通指標，並將結果輸入加權評分模組。

5.3 評估指標

本研究主要採用下列指標評估號誌策略效果：

- 一、平均等待時間：衡量車輛在路口或壅塞狀態下停等的平均時間。
- 二、行程延誤：衡量車輛實際行程時間相較於理想通行情況所增加的時間。
- 三、車流通過率：衡量單位時間內成功通過路口或路段之車輛比例。
- 四、排隊長度：衡量路口車隊累積程度，可反映是否出現回堵風險。
- 五、壅塞路段比例：衡量整體路網中處於低速或高密度狀態之路段占比。

其中，平均等待時間與行程延誤為本研究加權評分之核心指標，用以判斷不同號誌策略之整體效能。

5.4 號誌策略比較

本研究比較多種號誌控制策略，包含無控制基準、固定時制策略、依即時壅塞調整之策略，以及結合 GRU 預測結果的 adaptive 策略。無控制基準用於觀察未進行動態調整時的交通狀態；固定時制策略則代表傳統控制方式；adaptive 策略則根據預測車流與壅塞程度調整關鍵路口綠燈時間。

表 5.1 可用於整理各策略之設計邏輯與控制方式。

策略名稱	控制邏輯	是否使用 預測	是否動態調整 號誌	主要用途
無控制基準	不進行額外優化	否	否	作為比較基準
固定時制	依原始號誌週期執行	否	否	模擬傳統控制方式
即時壅塞調整	依當前壅塞程度調整	否	是	回應當下交通狀態
adaptive 策略	依 GRU 預測與壅塞程度調整	是	是	預先改善高流量方向

5.5 實驗結果

根據系統模擬結果，TrafficVision 已能完成每 5 分鐘自動抓取 VD 資料、執行模擬與預測、並行評估多種策略並更新前端儀表板。在高壅塞情境下，在自動排程模擬期間（405 次有效執行），系統最佳策略相較於無控制基準可降低平均等待時間約 8.6%、行程延誤約 7.3%，並減少車輛 teleport 次數由平均 1.94 降至 1.24（約 36%）。其中 adaptive 策略於 89 次（22.0%）的 runs 中獲選為最佳策略，於該等 runs 之平均綜合分數約 0.91。此結果顯示，若能根據即時資料與短時車流預測動態調整號誌秒數，可有效改善高車流情境下的停等問題。

此外，系統亦可同時呈現當前、預測與優化三種視角，使使用者能觀察策略前後之交通狀態差異。AI 助理能根據即時數據回答問題，協助使用者理解壅塞原因與策略調整邏輯。

表 5.2 可作為正式報告中的結果整理表。

評估項目	無控制基準	最佳策略平均	改善幅度
平均等待時間 (s)	39.10	35.73	-8.62%
行程延誤 (s)	47.95	44.43	-7.34%
平均行程時間 (s)	62.08	58.56	-5.68%
出發延誤 (s)	29.77	29.05	-2.44%
模擬結束時間 (s)	1406.85	1338.60	-4.85%
車輛 teleport 次數	1.94	1.24	-35.97%

註：彙整自 405 次有效自動排程模擬（466 次紀錄中 61 次因資料不足跳過）。最佳策略由加權分數（0.6·等待+0.4·延誤）於每次模擬選出，候選含 no_control、baseline_original、baseline_more_edges、baseline_more_edges_more_tls、adaptive 五種；adaptive 於 89 次（22.0%）獲選。改善經配對 Wilcoxon 檢定具統計顯著性（ $p < .001$ ）。

5.6 結果討論

從實驗結果可知，adaptive 策略在高壅塞情境下具有較明顯改善效果。其原因在於該

策略能根據 GRU 預測結果提前辨識高流量路段，並針對關鍵路口延長綠燈秒數，使車流能在壅塞擴大前獲得較佳疏導。

然而，號誌優化仍需考量整體路網平衡。若單純延長某方向綠燈，可能造成其他方向等待時間增加。因此，未來系統可進一步引入更多路網層級指標，例如整體平均旅行時間、交叉路口公平性、公共運輸優先與行人安全等，以提升策略決策的完整性。

第六章 結論與未來展望

6.1 研究結論

本研究完成一套整合即時開放資料、SUMO 微觀交通模擬、GRU 車流預測、多策略號誌評估、前端儀表板與大型語言模型問答介面之智慧交通號誌決策支援系統 TrafficVision。系統能定期抓取台北市 VD 即時資料，將資料轉換為 SUMO 模擬輸入，並透過 GRU 預測未來 5 分鐘車流變化，再以多策略並行模擬方式評估不同號誌控制方案。

實驗結果顯示，在高壅塞情境下，在自動排程模擬期間（405 次有效執行），系統最佳策略相較於無控制基準可降低平均等待時間約 8.6%、行程延誤約 7.3%，並減少車輛 teleport 次數由平均 1.94 降至 1.24（約 36%）。其中 adaptive 策略於 89 次（22.0%）的 runs 中獲選為最佳策略，於該等 runs 之平均綜合分數為 約 0.91。顯示本研究所提出之資料驅動號誌優化流程具有改善交通壅塞之潛力。此外，前端儀表板與 AI 問答介面能提升系統結果的可視性與可理解性，使交通管理人員更容易掌握當前路況、預測趨勢與優化建議。

6.2 系統效益

本研究系統具備三項主要效益。第一，透過即時開放資料與自動化排程，系統能快速反映交通狀態變化。第二，透過 SUMO 模擬，系統可在不影響真實道路運作的情況下測試號誌策略，降低實務導入風險。第三，透過 AI 助理與視覺化儀表板，系統能將複雜的交通模擬與模型結果轉化為使用者可理解的資訊。

6.3 研究限制

本研究目前仍以模擬環境作為主要驗證場域，尚未直接控制真實道路號誌。因此，模擬結果仍可能受到路網建置精度、車流需求假設、資料對應誤差與模型預測誤差影響。此外，GRU 模型主要處理時間序列變化，對於路段間空間依賴關係仍有進一步強化空間。

6.4 未來展望

未來研究可從以下方向延伸：

- 一、擴大監測範圍至整個中正區與大同區，提升系統於都市路網層級之應用性。
- 二、導入 Graph Neural Network (GNN)，學習路段與路口之間的空間依賴關係，進一步提升車流預測與號誌策略選擇效果。
- 三、評估與交通局實際號誌控制器串接之可能，使系統從模擬建議逐步邁向實際控制輔助。
- 四、增加歷史資料分析儀表板，提供週、月尺度之長期交通趨勢分析，協助交通管理單位進行政策規劃。
- 五、針對 GRU 預測模型，未來可探討加入路段空間結構之 attention 機制，並以更大規模、多時段之模擬資料重新訓練，進一步提升預測穩定性。

參考文獻

- [1] K. Cho et al., "Learning Phrase Representations using RNN Encoder – Decoder for Statistical Machine Translation," EMNLP, 2014.
- [2] P. A. Lopez et al., "Microscopic Traffic Simulation using SUMO," IEEE ITSC, 2018.
- [3] 台北市政府交通局，「即時交通車流量偵測資料 (VD)」，台北市資料大平台，
<https://data.gov.tw/dataset/25761>，存取日期：2026 年 4 月。
- [4] G. Gemma Team, "Gemma 2: Improving Open Language Models at a Practical Size," Google DeepMind Technical Report, 2024.

<https://blog.google/technology/developers/gemma-open-models/>

[5] PyTorch 2.6 Documentation, <https://pytorch.org/docs/2.6/> , 存取日期：2026 年 5 月。

[6] Leaflet 1.9 Documentation, <https://leafletjs.com/reference.html> , 存取日期：2026 年 5 月。

[7] Ollama Documentation, <https://github.com/ollama/ollama/blob/main/docs/api.md> ,

存取日期：2026 年 5 月。

[8] Papageorgiou, M., Diakaki, C., Dinopoulou, V., Kotsialos, A., and Wang, Y., "Review of road traffic control strategies," Proceedings of the IEEE, vol. 91, no. 12, 2003, pp. 2043 – 2067.

[9] Wei, H., Zheng, G., Yao, H., and Li, Z., "CoLight: Learning network-level cooperation for traffic signal control," ACM CIKM, 2019.

[10] Van der Pol, E. and Oliehoek, F., "Coordinated learning of traffic lights," NIPS Workshop on Learning, Inference and Control of Multi-Agent Systems, 2016.

[11] SUMO Documentation, OSMWebWizard Tutorial.

[12] SUMO Documentation, duarouter and Routing Modules.

附錄

附錄 A 系統流程圖

系統整體資料流分為兩條主要管線：

(1) 即時 VD 資料流：tools/fetch_vd_data.py 每 5 分鐘呼叫台北市

交通資料開放平台 API → 輸出至 trafficData/*.json → 由 serve_api.py

的 /api/traffic 端點即時供應前端顯示。

(2) 完整 ML 管線：tools/runtime_pipeline.py 依序執行 grabapi (API 抓取)

→ convertToRou (duarouter 路徑生成) → traffic_optimizer_io (SUMO 模擬)

→ predict_to_csv (GRU 預測) → traffic_light_optimizer (多策略並行評估)

→ generate_edge_heatmap (熱力圖 JSON) → 寫入 runtime_data/<stem>/handoff/。

附錄 B SUMO 模擬畫面

本研究模擬路網涵蓋國立臺北科技大學周邊主要幹道，含市民大道、八德路、

忠孝東路、新生南路四條主軸與其支線。整體 SUMO 路網包含 230 條 edge

(其中約 120 條為命名道路 edge，其餘為連通用內部 junction edge) 與

17 個受號誌控制路口。實際 SUMO-GUI 模擬截圖請參見專題報告附件。

附錄 C 時間甘特圖

本專題執行期間為 114 學年度第 1 學期至第 2 學期，主要分為下列階段：

階段 1 (Week 1-4) 文獻回顧與 SUMO 環境建置

階段 2 (Week 5-8) VD API 串接、資料正規化與路徑生成模組開發

階段 3 (Week 9-12) GRU 模型架構設計、訓練資料生成與初版訓練

階段 4 (Week 13-16) 多策略號誌評估、TraCI 控制流程整合

階段 5 (Week 17-20) 前端儀表板開發、Leaflet 地圖整合

階段 6 (Week 21-24) Gemma 4 微調、AI 問答介面整合

階段 7 (Week 25-28) 系統整合測試、實驗執行、報告撰寫

附錄 D 系統功能完成度

功能項目	完成狀態	說明
VD 資料抓取	已完成	每 5 分鐘自動更新
SUMO 模擬環境	已完成	建立北科大周邊路網 (230 edges, 17 號誌路口)
GRU 車流預測	已完成	pair model 同時預測 vehicle_count 與 avg_speed_kmh
號誌策略評估	已完成	5 種策略並行 SUMO 模擬比較
TraCI WebSocket 串流	已完成	/ws/simulation 每 10 模擬秒推送車輛動態
前端儀表板	已完成	React + Leaflet，呈現當前、預測與優化三視角
AI 問答介面	已完成	Gemma 4 (fine-tune via Unsloth) + 本地 Ollama
自動排程器	已完成	runtime_pipeline.py --interval 300
診斷端點	已完成	/api/health 提供資料新鮮度與系統狀態檢查
模型 holdout 評估	已完成	eval_speed_holdout.py 評估 speed channel 表現

符號彙編

符號或縮寫	說明
VD	Vehicle Detector，車輛偵測器資料
SUMO	Simulation of Urban Mobility，微觀交通模擬工具
TraCI	Traffic Control Interface，SUMO 即時控制介面
GRU	Gated Recurrent Unit，門控循環單元模型
LLM	Large Language Model，大型語言模型
API	Application Programming Interface，應用程式介面
OSM	OpenStreetMap，開放街圖
OD	Origin-Destination，起迄點需求
edge	SUMO 中的道路邊或路段
junction	SUMO 中的路口或節點
trip.xml	SUMO 旅次需求檔
route.xml	SUMO 車輛路徑檔
cDelta_x	SUMO 地圖於 X 方向之總長度
cDelta_y	SUMO 地圖於 Y 方向之總長度